

**Polytech Lyon**

Département Mathématiques Appliquées et Modélisation

# **Physics-Informed Neural Networks** **pour la modélisation pharmacocinétique**

Application aux modèles PBPK de distribution de médicaments

**Auteur** : NDAO Moth Yacine

**Tuteur** : M. CIUPERCA

**Formation** : MAM5

**Année universitaire** : 2025-2026

## Résumé

Ce rapport présente l'application des *Physics-Informed Neural Networks* (PINNs) à la modélisation pharmacocinétique physiologique (PBPK). Les PINNs combinent l'apprentissage profond avec des contraintes physiques pour résoudre des systèmes d'équations différentielles ordinaires (EDO) tout en estimant simultanément les paramètres du modèle. Nous comparons un modèle linéaire à 9 paramètres et un modèle PBPK biophysique à 4 paramètres, décrivant la distribution d'un médicament dans quatre compartiments corporels. Les résultats démontrent la capacité des PINNs à reconstruire avec précision les profils de concentration à partir d'observations partielles et bruitées (erreur  $< 5\%$ ), tout en identifiant les paramètres physiologiques sous-jacents. Une analyse d'identifiabilité révèle les corrélations entre certains paramètres PBPK, illustrant les limites de l'estimation paramétrique dans les modèles compartimentaux complexes.

**Mots-clés :** Physics-Informed Neural Networks, PBPK, Pharmacocinétique, Équations différentielles, Apprentissage profond, Estimation de paramètres

# 1 Introduction

## 1.1 Contexte et objectifs

La modélisation pharmacocinétique physiologique (PBPK) constitue un outil fondamental dans le développement de médicaments et la médecine personnalisée. Ces modèles décrivent mathématiquement la distribution des substances chimiques dans l'organisme en se basant sur des principes physiologiques. Cependant, leur calibration pose plusieurs défis : estimation de paramètres difficiles à mesurer *in vivo*, observations partielles, et problèmes d'identifiabilité.

Les *Physics-Informed Neural Networks* (PINNs), introduits par Raissi et al. (2019), offrent une approche novatrice pour résoudre simultanément le problème direct (prédiction) et inverse (estimation de paramètres). Les PINNs intègrent dans leur fonction de perte : (1) la fidélité aux données observées, (2) le respect des équations différentielles, et (3) la satisfaction des conditions initiales.

Ce travail vise à démontrer l'efficacité des PINNs pour la modélisation PBPK en comparant deux formulations mathématiques, évaluant la précision de reconstruction des profils de concentration, et caractérisant l'identifiabilité pratique des paramètres.

## 2 Modèles mathématiques

### 2.1 Modèle à 4 compartiments

Les deux modèles partagent une structure anatomique à quatre compartiments représentant : le sang cérébral ( $C_{bb}$ ), le tissu cérébral ( $C_{bm}$ ), le liquide céphalo-rachidien crânien ( $C_{ccsf}$ ) et spinal ( $C_{scsf}$ ).




Figure 1: Schéma du modèle PBPK à 4 compartiments. Les flèches indiquent les flux de transfert entre compartiments.

## 2.2 Modèle linéaire (9 paramètres)

Le système d'EDO du modèle linéaire s'écrit :

$$\begin{aligned}
\frac{dC_{bb}}{dt} &= k_{in} - k_{12}C_{bb} + k_{21}C_{bm} - k_{13}C_{bb} + k_{31}C_{ccsf} \\
\frac{dC_{bm}}{dt} &= k_{12}C_{bb} - k_{21}C_{bm} - k_{24}C_{bm} + k_{42}C_{scsf} \\
\frac{dC_{ccsf}}{dt} &= k_{13}C_{bb} - k_{31}C_{ccsf} - k_{34}C_{ccsf} + k_{43}C_{scsf} \\
\frac{dC_{scsf}}{dt} &= k_{24}C_{bm} + k_{34}C_{ccsf} - k_{42}C_{scsf} - k_{43}C_{scsf}
\end{aligned} \tag{1}$$

Les termes sont conservés séparés (par exemple  $-k_{12}C_{bb} - k_{13}C_{bb}$ ) car chaque terme représente un flux physique distinct entre compartiments spécifiques. Ainsi,  $k_{12}C_{bb}$  désigne le transfert du sang cérébral vers le tissu cérébral, tandis que  $k_{13}C_{bb}$  représente le transfert vers le LCR crânien.

Conditions initiales nulles :  $C_{bb}(0) = C_{bm}(0) = C_{ccsf}(0) = C_{scsf}(0) = 0$ .

Le modèle comporte 9 paramètres :  $\theta_{lin} = \{k_{in}, k_{12}, k_{21}, k_{13}, k_{31}, k_{24}, k_{42}, k_{34}, k_{43}\}$  ( $\text{h}^{-1}$ ).

## 2.3 Modèle PBPK biophysique (4 paramètres)

Nous notons  $\pi_{bb}$  le produit perméabilité-surface (*Permeability-Surface area product*) de la barrière hémato-encéphalique, et  $\pi_{csf}$  celui de la barrière hémato-LCR. Le système PBPK intègre des principes physiologiques explicites :

$$\begin{aligned}
\frac{dC_{bb}}{dt} &= \frac{1}{V_{bb}}(Q_{bb}(C_p - C_{bb}) - \pi_{bb}(C_{bb} - C_{bm})) \\
\frac{dC_{bm}}{dt} &= \frac{1}{V_{bm}}(\pi_{bb}(C_{bb} - C_{bm})) \\
\frac{dC_{ccsf}}{dt} &= \frac{1}{V_{ccsf}}(\pi_{csf}(C_{bb} - C_{ccsf}) - Q_{csf}C_{ccsf}) \\
\frac{dC_{scsf}}{dt} &= \frac{1}{V_{scsf}}(Q_{csf}C_{ccsf} - Q_{scsf}C_{scsf})
\end{aligned} \tag{2}$$

où  $C_p(t) = A \cdot e^{-\alpha t}$  simule une injection intraveineuse.

Les volumes  $V_{bb}, V_{bm}, V_{ccsf}, V_{scsf}$  sont des constantes physiologiques fixées à des valeurs anatomiques de référence (Tableau 1). Ces volumes sont parfaitement connus et ne sont donc pas des paramètres à identifier.

Table 1: Volumes compartimentaux (valeurs fixes)

| Compartiment                | Volume (L) | Réf.    |
|-----------------------------|------------|---------|
| Sang cérébral ( $V_{bb}$ )  | 0.050      | ICRP 89 |
| Tissu cérébral ( $V_{bm}$ ) | 1.400      | ICRP 89 |
| LCR crânien ( $V_{ccsf}$ )  | 0.120      | ICRP 89 |
| LCR spinal ( $V_{scsf}$ )   | 0.080      | ICRP 89 |

Le modèle PBPK comporte 4 paramètres libres :  $\theta_{PBPK} = \{\pi_{bb}, \pi_{csf}, Q_{bb}, A\}$ .

## 2.4 Comparaison des formulations

Les modèles (1) et (2) sont deux formulations indépendantes et alternatives du même problème physique. Le modèle linéaire adopte une approche phénoménologique, tandis que le modèle PBPK adopte une approche mécanistique. Les deux décrivent les mêmes variables physiques (concentrations dans les mêmes compartiments), ce qui justifie l'utilisation des mêmes notations.

## 3 Méthodologie PINN

### 3.1 Principe et notation

Dans la suite, nous utilisons la notation indicée avec la correspondance :

$$C_1 = C_{bb}, \quad C_2 = C_{bm}, \quad C_3 = C_{ccsf}, \quad C_4 = C_{scsf}$$

### 3.2 Architecture du réseau

Le PINN adopte une architecture *fully-connected* : entrée  $t \in [0, 48]$ h, 6 couches cachées de 50 neurones avec activation tanh, sortie  $\mathbf{C}(t) = [C_1, C_2, C_3, C_4]^T$ .




Figure 2: Architecture du PINN. Le temps  $t$  est l'entrée unique. Le réseau optimise conjointement les poids  $\mathbf{W}$  et les paramètres physiques  $\theta$ .

Le PINN optimise deux ensembles de variables distincts :

- Les poids synaptiques du réseau :  $\mathbf{W} = \{W^{(1)}, b^{(1)}, \dots, W^{(L)}, b^{(L)}\}$
- Les paramètres physiques :  $\theta_{lin} = \{k_{ij}\}$  (9 param.) ou  $\theta_{PBPK} = \{\pi_{bb}, \pi_{ccsf}, Q_{bb}, A\}$  (4 param.)

La prédiction s'écrit :  $C_j(t_i; \mathbf{W}, \theta) = \text{NN}_j(t_i; \mathbf{W})$ , où les paramètres  $\theta$  interviennent uniquement dans le calcul de  $f_j(\mathbf{C}, \theta)$  pour la perte  $\mathcal{L}_{ODE}$ .

### 3.3 Fonction de perte multi-objectifs

La fonction de perte totale combine trois termes :

$$\mathcal{L}_{total}(\mathbf{W}, \theta) = w_{data} \cdot \mathcal{L}_{data} + w_{IC} \cdot \mathcal{L}_{IC} + w_{ODE} \cdot \mathcal{L}_{ODE} \quad (3)$$

**Perte sur les données :**  $\mathcal{L}_{data} = \frac{1}{N_{obs}} \sum_{i=1}^{N_{obs}} \sum_{j \in \{1,3\}} (C_j(t_i) - C_j^{obs}(t_i))^2$

**Perte sur les conditions initiales :**  $\mathcal{L}_{IC} = \sum_{j=1}^4 (C_j(t=0))^2$

**Perte sur les EDO :**  $\mathcal{L}_{ODE} = \frac{1}{N_{coll}} \sum_{k=1}^{N_{coll}} \sum_{j=1}^4 \left( \frac{\partial C_j}{\partial t} \Big|_{t_k} - f_j(\mathbf{C}(t_k), \theta) \right)^2$

La dérivée  $\frac{\partial C_j}{\partial t}$  est calculée par différentiation automatique (PyTorch).

**Pondération :**  $w_{data} = 1.0$ ,  $w_{IC} = 10.0$ ,  $w_{ODE} = 0.1$

### 3.4 Optimisation

Nous utilisons l'optimiseur Adam (*Adaptive Moment Estimation*), un algorithme basé sur le gradient qui adapte le taux d'apprentissage pour chaque paramètre. Les équations de mise à jour sont :

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\mathbf{W}, \theta} \mathcal{L}_{total} \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\mathbf{W}, \theta} \mathcal{L}_{total})^2 \\ (\mathbf{W}, \theta)_{t+1} &= (\mathbf{W}, \theta)_t - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \end{aligned}$$

avec  $\alpha = 10^{-3}$ ,  $\beta_1 = 0.9$ ,  $\beta_2 = 0.999$ , 20 000 itérations.

Adam nécessite le gradient  $\nabla_{\mathbf{W}, \theta} \mathcal{L}_{total}$  par rapport aux poids du réseau et aux paramètres physiques simultanément. Ce gradient est calculé automatiquement par différentiation automatique (PyTorch *autograd*). La difficulté des PINNs réside dans le calcul de  $\frac{\partial C_j}{\partial t}$ , qui constitue un gradient d'ordre supérieur, géré par l'option `create_graph=True`.

**Points de collocation :**  $N_{coll} = 2000$  points uniformément répartis dans  $[0, 48]$ h :  $t_k = k \cdot \frac{48}{2000}$  pour  $k = 0, \dots, 1999$ .

**Données synthétiques :** Résolution numérique (Runge-Kutta), 200 points d'observation, bruit gaussien 2%, observations partielles ( $C_{bb}$  et  $C_{ccsf}$  uniquement).

## 4 Résultats expérimentaux

### 4.1 Modèle linéaire (9 paramètres)

Observations :

- Compartiments observés : RMSE < 0.05 mg/L,  $R^2 > 0.99$
- Compartiments latents : Excellente extrapolation
- Erreur paramétrique moyenne : **5.4%**

### 4.2 Modèle PBPK (4 paramètres)

**Caractéristiques :** Pic sanguin à  $t \approx 0.5$ h, accumulation tissulaire progressive, sous-estimation du pic (0.75 vs 1.2 mg/L).


Figure 3: **Modèle linéaire** : Reconstruction fidèle des profils temporels.

Table 2: Estimation paramètres modèle linéaire

| Param.           | Vraie | Estimation      | Erreur (%) |
|------------------|-------|-----------------|------------|
| $k_{in}$         | 0.80  | $0.78 \pm 0.03$ | 2.5        |
| $k_{12}$         | 0.60  | $0.62 \pm 0.04$ | 3.3        |
| $k_{21}$         | 0.25  | $0.24 \pm 0.02$ | 4.0        |
| Erreur moyenne : |       |                 | 5.4%       |

### 4.3 Analyse comparative

Le modèle linéaire présente une meilleure précision ( $R^2 > 0.98$ ) grâce à sa flexibilité. Le modèle PBPK offre une meilleure interprétabilité avec seulement 4 paramètres.

## 5 Discussion et identifiabilité

### 5.1 Points forts et limites

Points forts :

- Résolution simultanée problème direct/inverse
- Robustesse au bruit (régularisation EDO)
- Extrapolation compartiments latents

Limites :

- Difficulté avec transitoires rapides (sous-estimation 25-35%)
- Sensibilité à l'initialisation ( $\pm 15\%$ )
- Coût computationnel (gradients d'ordre 2)




Figure 4: **Modèle PBPK** : Pic rapide de  $C_{bb}$  suivi d'une décroissance exponentielle.

Table 3: Estimation paramètres PBPK

| Param.                  | Unité | Vraie | Estim.          | Err. (%)     |
|-------------------------|-------|-------|-----------------|--------------|
| $\pi_{bb}$              | L/h   | 0.15  | $0.14 \pm 0.02$ | 6.7          |
| $\pi_{csf}$             | L/h   | 0.08  | $0.09 \pm 0.01$ | 12.5         |
| $Q_{bb}$                | L/h   | 0.50  | $0.48 \pm 0.04$ | 4.0          |
| $A$                     | mg/L  | 1.00  | $0.75 \pm 0.05$ | 25.0         |
| <b>Erreur moyenne :</b> |       |       |                 | <b>12.0%</b> |

## 5.2 Identifiabilité paramétrique

Matrice de corrélation des paramètres PBPK : forte corrélation  $\rho(\pi_{bb}, Q_{bb}) = 0.87$  révélant un couplage. Cette non-identifiabilité intrinsèque limite la précision des estimations individuelles, bien que leur combinaison fonctionnelle (clairance totale) puisse être bien identifiée.

## 5.3 Perspectives

**Extensions** : PINNs bayésiens (quantification incertitude), collocation adaptative, multi-fidelity learning.

**Applications cliniques** : Médecine personnalisée, optimisation posologique, discovery de médicaments.

## 6 Conclusion

Ce travail a démontré l'efficacité des PINNs pour la modélisation PBPK avec erreurs  $< 5\%$  sur compartiments observés et estimation paramétrique  $< 13\%$  d'erreur moyenne. L'analyse d'identifiabilité a révélé le couplage  $\pi_{bb} \leftrightarrow Q_{bb}$ . Malgré les limitations (pics transitoires, absence de quantification d'incertitude), les PINNs ouvrent des perspectives majeures : réduction des tests animaux, accélération du développement de médicaments, et médecine de précision.

## Références

- [1] M. Raissi, P. Perdikaris, G.E. Karniadakis, *Physics-informed neural networks*, J. Comput. Phys., 378:686-707, 2019.
- [2] D.P. Kingma, J. Ba, *Adam: A method for stochastic optimization*, ICLR 2015.
- [3] ICRP, *Basic anatomical and physiological data*, Publication 89, 2002.

## A Code PyTorch du PINN

```
import torch
import torch.nn as nn

class PINN(nn.Module):
    def __init__(self, layers=[1, 50, 50, 50, 50, 50, 50, 4]):
        super(PINN, self).__init__()
        self.layers = nn.ModuleList()
        for i in range(len(layers)-1):
            self.layers.append(nn.Linear(layers[i], layers[i+1]))

    def forward(self, t):
        x = t
        for i, layer in enumerate(self.layers[:-1]):
            x = torch.tanh(layer(x))
        x = self.layers[-1](x)
        return x # [C_bb, C_bm, C_ccsf, C_scsf]

# Paramètres physiques
params_phy = nn.Parameter(torch.randn(4))

# Optimiseur Adam
optimizer = torch.optim.Adam(
    list(model.parameters()) + [params_phy],
    lr=1e-3, betas=(0.9, 0.999)
)

# Dérivée temporelle (auto-diff)
def compute_derivative(model, t):
    t.requires_grad_(True)
    C = model(t)
    dC_dt = torch.autograd.grad(
        C, t, grad_outputs=torch.ones_like(C),
        create_graph=True # Gradients ordre 2
    )[0]
    return C, dC_dt
```